ANÁLISIS

Vulnerabilidad de Empleos a la Inteligencia Artificial en España

Metodología completa, datos, supuestos, limitaciones y hallazgos principales

502 ocupaciones · 22,46 millones de trabajadores · EPA Q4 2025 · Censo 2021

Marzo 2026 · Versión 23 · 50 notas técnicas

Indicador	Valor	Nota
Ocupaciones analizadas	502 CNO-11 completa	Taxonomía SEPE
Trabajadores representados	22,46 millones	EPA Q4 2025 (datos definitivos)
Exposición media ponderada	3.7 / 10	Calibrada España (5 factores + sub-componentes)
Empleos en alta exposición (≥7)	12.5%	2.81M trab. [≥6,5: 15.7% | ≥7,5: 11.4%]
Índice ponderado de exposición	257,060M EUR	Empleo × Salario × (Score/10) — índice, no predicción
Rango salarial	12.985 – 79.282 EUR/año	EES 2023 + ajuste educativo + proxies
Validación inter-modelo (r)	0,715	100 ocupaciones, Gemini vs GPT-4o blind
Validación sub-componente (177 occ)	85-90% dentro ±1,0	GPT 5.4 vs Gemini 3, 4 dimensiones, 2 clusters
Validación salarial (MAPE)	4,96%	16 grupos INE EES 2023, post-corrección
Validación empleo 1-dígito	±0,00%	EPA Q4 2025 exacto (API Tempus tabla 65134)

© 2026 Álvaro de Nicolás. Todos los derechos reservados. Este documento está protegido por derechos de autor. Para autorizaciones: alvarodenicolas.com

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

1. Qué es esto y por qué importa

La inteligencia artificial está transformando el mundo del trabajo. ¿Pero cuánto afecta realmente a cada profesión en España? ¿Es lo mismo ser albañil que contable frente a la IA?

Este análisis examina las 502 ocupaciones oficiales del mercado laboral español y asigna a cada una una puntuación de exposición a la IA en una escala de 0 a 10. Un 0 significa que la IA prácticamente no puede realizar las tareas de esa profesión (por ejemplo, un albañil o un bombero). Un 10 significa que la IA ya puede realizar la mayoría de las tareas de esa profesión con calidad comparable a la humana (por ejemplo, un grabador de datos).

El resultado es un mapa visual interactivo — un treemap — donde cada rectángulo representa una ocupación. El tamaño del rectángulo indica cuánta gente trabaja en esa profesión, y el color indica su nivel de exposición a la IA: azul oscuro para exposición baja, y tonos cálidos (ámbar, terracota) para exposición alta.

2. Cómo se hizo: la metodología paso a paso

El proceso se puede resumir en cinco fases. Cada una utiliza fuentes oficiales y públicas del sistema estadístico español, complementadas con proxies internacionales donde la granularidad española es insuficiente.

3. Fase 1: El inventario de ocupaciones

España clasifica todas las profesiones mediante un sistema llamado CNO-11 (Clasificación Nacional de Ocupaciones), gestionado por el Instituto Nacional de Estadística (INE). Este sistema organiza el trabajo en cuatro niveles jerárquicos: desde 10 grandes grupos (directivos, profesionales, técnicos, administrativos, etc.) hasta 502 ocupaciones específicas al nivel más detallado.

Para este análisis, partimos de la taxonomía completa CNO-11 con sus 502 códigos a 4 dígitos. Cada código tiene un nombre oficial — desde 'Albañiles' (código 7121) hasta 'Analistas y diseñadores de software' (código 2712). La taxonomía completa se descargó del catálogo de datos abiertos de datos.gob.es y se validó contra las tablas INEbase.

4. Fase 2: Los datos de empleo

Los datos de cuántas personas trabajan en España proceden de la Encuesta de Población Activa (EPA), la encuesta de referencia del INE. Utilizamos los microdatos de la EPA del cuarto trimestre de 2025 (publicados el 27 de enero de 2026), que arrojan un total de 22,46 millones de ocupados — cifra validada con el dato oficial del INE con un error del 0,00%.

Totales EPA Q4 2025 por gran grupo (cifras exactas)

Las siguientes cifras se han extraído de la API Tempus del INE (tabla 65134) y constituyen los totales oficiales publicados:

CNO	Gran Grupo	Empleados	% Total
1	Directores y gerentes	939.800	4,2%
2	Técnicos y profesionales científicos e intelectuales	4.618.700	20,6%

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

CNO	Gran Grupo	Empleados	% Total
3	Técnicos; profesionales de apoyo	2.685.200	12,0%
4	Empleados contables, administrativos y de oficina	2.132.500	9,5%
5	Trabajadores restauración, personales, protección y vendedores	4.713.600	21,0%
6	Trabajadores cualificados agrícola/ganadero/forestal/pesquero	437.200	1,9%
7	Artesanos y cualificados manufactura y construcción	2.386.200	10,6%
8	Operadores de instalaciones, maquinaria y montadores	1.684.600	7,5%
9	Ocupaciones elementales	2.766.100	12,3%
0	Ocupaciones militares	99.400	0,4%
	TOTAL	22.463.300	100,0%

La limitación de la distribución a 4 dígitos

La EPA publica datos de empleo a nivel de 'gran grupo' (1 dígito, 10 categorías), no al detalle de las 502 ocupaciones individuales. Los microdatos públicos anonimizan la ocupación a 1 dígito por diseño del INE.

Esto significa que las cifras de empleo a 4 dígitos CNO que se muestran en el dashboard interactivo son estimaciones, no datos observados directamente. La distribución se realizó en dos etapas: (1) se aplicaron pesos estructurales del Censo de Población y Viviendas 2021 (INE, 145 subgrupos a 3 dígitos CNO) como prior para redistribuir los totales EPA dentro de cada gran grupo; (2) los totales a 3 dígitos resultantes se refinaron mediante contracción empírico-bayesiana (Empirical Bayes shrinkage) en espacio logarítmico, que combina la estimación EPA con el prior censal ponderando cada señal por su contenido informativo. El factor de contracción B varía entre 0,05 y 0,97 según el subgrupo — subgrupos pequeños o con divergencia alta entre EPA y Censo se contraen más hacia el prior censal. El resultado son 202 valores únicos de empleo (frente a los 134 de la distribución proporcional pura), preservando los totales EPA a 1 dígito con exactitud absoluta (véase nota [45]). El usuario debe interpretar estas cifras como órdenes de magnitud, no como recuentos precisos por ocupación individual.

Validación de empleo: EPA 2-dígitos Q4 2025

La tabla 65134 del INE también publica datos a 2 dígitos (50 subgrupos). Nuestra distribución, basada en pesos del Censo 2021 a 3 dígitos con refinamiento bayesiano, muestra desviaciones a nivel de 2 dígitos que oscilan entre ±0% y ±540%. Estas desviaciones son esperables: los pesos censales de 2021 no reflejan los cambios estructurales del mercado laboral entre 2021 y 2025. Una re-ponderación directa con los totales EPA a 2 dígitos es la mejora prioritaria para futuras versiones.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

5. Fase 2b: Los datos salariales y sus ajustes

Los datos salariales proceden de la Encuesta de Estructura Salarial (EES) de 2023 del INE (tabla 28186), que proporciona el salario bruto medio anual a nivel de subgrupo CNO de 2 dígitos (16 grupos).

Ajuste 1: Prima educativa INE

El INE publica datos de primas salariales por nivel educativo alcanzado. Aplicamos un multiplicador a cada ocupación según el nivel de estudios típico que requiere.

Ajuste 2: Proxies internacionales (Francia y Portugal)

Francia (INSEE) y Portugal (INE-PT) publican datos salariales con mayor granularidad ocupacional que España. Utilizamos las diferencias salariales relativas dentro de cada grupo en estos países como proxy para estimar la varianza intra-grupo en España. El resultado es un rango salarial de 12.985 EUR a 79.282 EUR con 128 valores únicos.

Ajuste 3: Correcciones post-validación (v5)

Tras la validación cruzada contra los datos publicados del INE EES 2023 (16 grupos), se aplicaron correcciones específicas a los tres grupos con mayor desviación:

Grupo I (Protección y seguridad): Las estimaciones iniciales (22.383 EUR de media) subvaloraban gravemente las retribuciones del sector público de seguridad. Se corrigieron al alza las fuerzas de seguridad del Estado (Policía Nacional/Autonómica → 42.000 EUR, Guardia Civil → 38.000 EUR, Bomberos → 40.000 EUR) para reflejar los complementos de trienios, peligrosidad y nocturnidad. Resultado: desviación de -36,4% → -4,4%.

Grupo M (Operadores maquinaria fija): Ajuste del +12% en CNO 81xx/82xx para reflejar convenios colectivos del metal y la química. Resultado: desviación de -12,0% → -1,4%.

Grupo H (Salud y cuidados): Reducción de salarios de cuidadores a domicilio y de niños hacia el SMI + complementos mínimos (~16.000-16.500 EUR). Resultado: desviación de +9,7% → +5,2%.

Validación salarial completa (16 grupos INE EES 2023)

Grupo	Nombre	INE (EUR)	Nuestro (EUR)	Desv. %
A	Directores y gerentes	60.986	57.922	-5,0%
B	Técnicos prof. científicos (salud/enseñanza)	38.858	38.099	-2,0%
C	Otros técnicos prof. científicos	42.997	40.100	-6,7%
D	Técnicos; profesionales de apoyo	33.243	31.381	-5,6%
E	Empleados oficina (sin atención público)	28.148	25.564	-9,2%
F	Empleados oficina (con atención público)	22.263	24.018	+7,9%
G	Trab. restauración, comercio, personales	18.028	17.526	-2,8%
H	Trab. servicios salud y cuidado	18.739	19.717	+5,2%
I	Trab. protección y seguridad	35.215	33.667	-4,4%
J	Trab. cualificados agro/forestal/pesca	24.551	23.937	-2,5%

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Grupo	Nombre	INE (EUR)	Nuestro (EUR)	Desv. %
K	Trab. cualificados construcción	23.321	23.713	+1,7%
L	Trab. cualificados industrias manuf.	26.345	23.881	-9,4%
M	Operadores instalaciones/maquinaria fijas	28.852	28.446	-1,4%
N	Conductores/operadores maquinaria móvil	23.536	22.895	-2,7%
O	Trab. no cualificados en servicios	15.277	14.600	-4,4%
P	Peones agricultura/pesca/constr./industria	20.817	19.051	-8,5%
	MAPE (Error absoluto medio porcentual)			4,96%

Fuente de validación: INE, Encuesta Anual de Estructura Salarial 2023, Tabla 28186. Validación realizada por Manus AI (marzo 2026). Las 16 desviaciones son inferiores al 10%.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

6. Fase 3: La puntuación de exposición a la IA

Cada una de las 502 ocupaciones recibe una puntuación de 0 a 10 que mide hasta qué punto la inteligencia artificial actual podría realizar las tareas principales de esa profesión.

Paso 3a: Puntuación base por tareas

Las puntuaciones se generaron mediante análisis de modelos de lenguaje (LLM) siguiendo la línea metodológica establecida por Brynjolfsson et al. (2018) con sus rúbricas de 'Suitability for Machine Learning', adaptada por Eloundou et al. (2023) en 'GPTs are GPTs' para la taxonomía O*NET, y aplicada aquí a la CNO-11 española con calibración estructural: puntuación en un solo pase con prompts de rúbrica estructurados a temperatura baja (0,2) para garantizar la reproducibilidad.

Diferencia con el marco Eloundou et al. (2023): Eloundou opera a nivel de tarea (19.265 tareas O*NET agregadas a ocupaciones), mientras que este análisis puntúa a nivel de ocupación. La CNO-11 no dispone de un inventario de tareas equivalente al O*NET (nota [38]). Adicionalmente, Eloundou distingue entre exposición directa al LLM (α) y exposición mediada por software complementario (β, ζ); nuestra escala continua 0-10 subsume ambas dimensiones en una puntuación única (nota [40]).

Eloundou también demuestra que pequeñas modificaciones al prompt de clasificación producen variaciones significativas en la concordancia (Tabla 2 de su paper), lo que refuerza la decisión metodológica de este análisis de utilizar prompts de rúbrica estructurados a temperatura baja (0,2) con anclajes explícitos para minimizar la varianza intra-modelo.

Para cada ocupación se generó una justificación detallada de 3-4 frases en español que explica el vector principal de automatización y los factores que protegen el componente humano de la profesión.

Paso 3b: Validación inter-modelo (v10; ampliada en v11a)

Se realizó una validación inter-modelo ciega de 100 ocupaciones estratificadas por un segundo LLM (GPT-4o) sin acceso a las puntuaciones originales (Gemini 2.5 Pro). Los resultados:

Métrica	Valor	Interpretación
Correlación de Pearson (r)	0,715	Buena — rango 'good' para inter-rater reliability
ICC(2,1)	0,701	Buena — acuerdo consistente entre modelos
Kappa ponderado (kw cuadrático)	0,667	Acuerdo sustancial (convención Landis-Koch)
Sesgo medio (GPT - Gemini)	+0,28 puntos	GPT puntúa ligeramente más alto
MAD (desviación absoluta mediana)	1,0 punto	En una escala 0-10, excelente
Ocupaciones dentro de ±1,0 punto	61%	Acuerdo estrecho
Ocupaciones dentro de ±2,0 puntos	84%	Acuerdo amplio
Desacuerdos >2,0 puntos	16 (de 100)	Concentrados en 2 clusters interpretables

Patrón de desacuerdo sistemático: GPT comprime hacia el centro: puntúa ocupaciones físicas/manuales más alto (+1,07 en banda 0-3) y ocupaciones de conocimiento más bajo (-1,00 en banda 7+). Los 16 desacuerdos grandes se concentran en dos clusters: (1) GPT valora más el potencial de automatización industrial (CNO 81xx/82xx), y (2) Gemini valora más el componente digital de profesiones nicho (notarios, actores, enólogos). Los 84% restantes de puntuaciones son robustos entre modelos.

Conclusión: Las puntuaciones no son artefactos de un modelo único — el ranking se preserva sustancialmente (r = 0,715) y los desacuerdos son interpretables y concentrados, no aleatorios.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Análisis Bland-Altman (v11a): Se realizó un análisis Bland-Altman de sesgo sistemático sobre las 100 ocupaciones validadas. El sesgo medio (GPT - Gemini) es de +0,28 puntos, confirmando que GPT-4o puntúa ligeramente por encima de Gemini 2.5 Pro de forma consistente. Los límites de acuerdo al 95% (±1,96 DE) son -2,77 a +3,33 puntos. El gráfico no muestra sesgo proporcional: las diferencias no aumentan ni disminuyen sistemáticamente con el nivel medio de puntuación, lo que confirma que el acuerdo entre modelos es homogéneo en todo el rango 0-10.

Posición comparativa: Ninguna herramienta comparable a nivel internacional (willrobotstakemyjob.com, replacedbyrobot.info, OECD AI Exposure Index, ILO GenAI Exposure Index) ha publicado validación inter-modelo con análisis Bland-Altman. La herramienta de Frey y Osborne (2013) utilizó estimaciones de un único panel de expertos sin re-puntuación ciega. El ILO GenAI Exposure Index (2024) utilizó GPT-4 como motor único sin validación cruzada. Esta validación sitúa el presente análisis en el estándar más alto de fiabilidad publicado para herramientas de exposición laboral a la IA. (Véase Apéndice B para gráficos detallados).

Adicionalmente, las 88 ocupaciones que recibieron una puntuación idéntica de 7,0 y las 89 ocupaciones en 5,0 fueron re-puntuadas mediante descomposición en sub-componentes (véanse Pasos 3d y 3e).

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Paso 3c: Los 5 factores de calibración España

A diferencia de los enfoques de puntuación LLM que aplican una heurística binaria ('si el trabajo se hace desde un portátil, la exposición es 7+'), este análisis aplica cinco modificadores estructurales específicos de España:

· **Índice de digitalización DESI** — España ocupa el puesto 3 de la UE en digitalización general (DESI 2023, 69,8 puntos — nota: la Comisión Europea ya no publica el índice DESI compuesto a partir de 2024). Sin embargo, baja al puesto 11 en integración de tecnologías digitales por empresas. Solo el 8% de las empresas españolas utiliza IA (cifra conservadora; Banco de España 2025 estima ~20%, INE TIC 2025 ~21%). Factor de moderación por sector: 0,80 (agricultura) a 0,95 (tecnología/banca).

· **Peso del sector servicios** — La economía española depende de los servicios en un 74% (frente al 68% de media UE), y el turismo representa el 12,4% del PIB.

· **Protección laboral** — España tiene la tercera legislación de protección del empleo más estricta de la OCDE. Indemnización por despido improcedente: 33 días/año (máximo 24 mensualidades). Factor de fricción: 1-5% según sector.

· **Reglamento Europeo de IA (EU AI Act)** — El Reglamento (UE) 2024/1689 clasifica los usos de sistemas de IA — no las ocupaciones en sí — en cuatro niveles de riesgo. 51 ocupaciones en contextos de uso de alto riesgo (3.48M trabajadores). Factor de moderación: 2-8% para categorías de alto riesgo.

· **Supervisión AESIA** — España es el primer país de la UE con una agencia estatal de supervisión de IA operativa (A Coruña, Real Decreto 729/2023). Multas de hasta 35M EUR o 7% de facturación global.

El efecto combinado produce una reducción del 11-12% sobre la puntuación base. Fórmula: score_ajustado = score_base × factor_DESI × (1 – fricción_regulatoria) × (1 – fricción_laboral)

Análisis de sensibilidad de los factores de calibración

Escenario	Exp. media	Alta exp. (≥7)	Índice pond. exp.
Calibración actual (base)	3.7 / 10	12.5%	257,060M EUR
Todos los factores –20%	~4,8 / 10	Estimación no lineal	~321.600M EUR
Todos los factores +20%	~3,1 / 10	Estimación no lineal	~214.400M EUR

Paso 3d: Re-puntuación por sub-componentes (v22; 88 ocupaciones frontera)

El scoring holístico en un solo pase (Paso 3a) produjo una concentración de 88 ocupaciones en la puntuación exacta de 7,0 (2,66M trabajadores). Esta concentración (*score heaping*) hacía que la cifra de alta exposición fuese extremadamente sensible al umbral: desplazar ±0,5 puntos movía el titular entre el 9% y el 22%. Para resolver esta fragilidad, se diseñó un protocolo de re-puntuación por descomposición dimensional (aplicado también al cluster 5,0 en el Paso 3e).

Metodología: Las 88 ocupaciones fueron re-puntuadas independientemente por dos modelos frontier (GPT 5.4 Thinking y Gemini 3 Thinking) en conversaciones nuevas sin contexto previo (scoring ciego). Cada modelo evaluó 4 sub-componentes en escala 0-10 (incrementos 0,5):

D — Digitalización de tareas: porcentaje de tareas principales que son información-puras o digitales.
C — Capacidad actual de la IA: calidad con la que la IA actual puede realizar las tareas digitales.
F — Barrera físico-presencial: cuánto exige el trabajo presencia física, manipulación manual o desplazamiento.
R — Fricción regulatoria-institucional: cuánto frenan la regulación, certificación o responsabilidad legal la adopción de IA.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Fórmula: score_raw = (D × C / 10) × (1 – F/20) × (1 – R/20). La puntuación bruta se promedió entre modelos y se re-escaló linealmente al rango [3,0 – 8,5] para preservar el ranking relativo y la coherencia con las puntuaciones holísticas del resto del dataset. Redondeo a incrementos de 0,5 puntos.

Acuerdo inter-modelo (sub-componentes)

Métrica	Valor	Interpretación
Ocupaciones dentro de ±1,0 punto	85% (75/88)	Mejor que scoring holístico (61%)
Ocupaciones dentro de ±2,0 puntos	99% (87/88)	Mejor que scoring holístico (84%)
Sesgo sistemático (GPT – Gemini)	–0,02 puntos	Esencialmente nulo
Diferencia absoluta mediana	0,43 puntos	Excelente en escala 0-10

Resultado: Las 88 ocupaciones se redistribuyeron en 12 valores de puntuación distintos (rango 3,0 – 8,5), reduciendo la concentración en 7,0 de 88 a 6 ocupaciones. La banda de sensibilidad del umbral se estrechó de [9,0% – 22,2%] a [11.4% – 15.7%].

Ejemplos de diferenciación

Ocupación	D	C	F	R	Antes	Después
Diseñadores gráficos y multimedia	9,5	9,0	0,0	0,0	7,0	8,5
Asistentes jurídico-legales	9,2	8,8	1,0	3,5	7,0	7,0
Jueces y magistrados	9,5	7,8	1,5	9,8	7,0	5,0
Ingenieros técnicos obras públicas	6,2	6,2	7,2	4,8	7,0	4,0
Higienistas bucodentales	2,0	4,5	9,5	6,5	7,0	3,0

[49] Re-puntuación por sub-componentes (v22-v23). 177 ocupaciones fueron re-puntuadas por GPT 5.4 Thinking y Gemini 3 Thinking mediante descomposición en 4 dimensiones: Digitalización (D), Capacidad IA (C), Barrera física (F) y Fricción regulatoria (R). Fórmula: score_raw = (D×C/10) × (1–F/20) × (1–R/20). Cluster 7.0 (v22): 88 ocupaciones con score holístico 7,0, re-escaladas a [3,0–8,5]. Acuerdo: 85% ±1,0 (n=88), sesgo –0,02. Cluster 5.0 (v23): 89 ocupaciones con score holístico 5,0 (excluyendo 13 ya re-puntuadas del cluster 7.0), re-escaladas a [2,5–7,5]. Acuerdo: 90% ±1,0 (n=89), mediana diferencia 0,42, sesgo ~0. Los campos score_v8/score_v9, rescore_method, rescore_cluster, rescore_D/C/F/R y rescore_raw_avg proporcionan trazabilidad completa en el dataset publicado.

Paso 3e: Re-puntuación por sub-componentes (v23; 89 ocupaciones en 5,0)

El mismo protocolo del Paso 3d se aplicó a las 89 ocupaciones con puntuación holística de 5,0 que no habían sido re-puntuadas previamente (13 ocupaciones del cluster 5,0 ya habían recibido nuevas puntuaciones como parte del cluster 7,0). La concentración de 102 ocupaciones en la puntuación exacta de 5,0 representaba el mayor *heap* restante tras la resolución del cluster 7,0.

Metodología: Idéntica al Paso 3d. Las 89 ocupaciones fueron evaluadas independientemente por GPT 5.4 Thinking y Gemini 3 Thinking en 3 lotes (30+30+29), con los mismos 4 sub-componentes (D, C, F, R) y la misma fórmula multiplicativa. Los scores brutos se promediaron entre modelos y se re-escalaron linealmente al rango [2,5–7,5] — un rango más estrecho que el cluster 7,0 ([3,0–8,5]) para reflejar que estas son ocupaciones de rango medio.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Acuerdo inter-modelo (5.0 cluster)

Métrica	Valor	Interpretación
Ocupaciones dentro de ±1,0 punto	90% (80/89)	Mejor que cluster 7.0 (85%)
Diferencia absoluta mediana	0,42 puntos	Excelente en escala 0-10
Sesgo sistemático (GPT – Gemini)	~0,0 puntos	Esencialmente nulo
Ocupaciones que cambiaron score	87/89 (98%)	Solo 2 permanecieron en 5,0

Resultado: Las 89 ocupaciones se redistribuyeron en 10 valores de puntuación distintos (rango 2,5–7,5), reduciendo la concentración en 5,0 de 102 a 15 ocupaciones. El *heap* máximo del dataset pasó de 102 ocupaciones (en 5,0) a 77 ocupaciones (en 2,5, un valor no frontera). Esto resolvió el Issue #7 del registro adversarial.

Ejemplos de diferenciación (5.0 cluster)

Ocupación	D	C	F	R	Antes	Después
Traductores e intérpretes	9,5	9,3	0,5	1,0	5,0	7,5
Tenedores de libros	9,5	9,0	0,5	2,0	5,0	7,0
Atletas y deportistas	2,0	3,0	10,0	0,5	5,0	2,5
Vendedores en tiendas	5,0	5,5	6,0	0,5	5,0	3,0
Chefs	4,0	4,5	8,5	1,0	5,0	2,5

[50] Re-puntuación cluster 5.0 (v23). 89 ocupaciones con score holístico de 5,0 (excluyendo 13 ya re-puntuadas del cluster 7,0) fueron re-puntuadas por GPT 5.4 Thinking y Gemini 3 Thinking mediante el mismo protocolo de 4 sub-componentes del Paso 3d. Re-escalado lineal a [2,5–7,5]. 87/89 (98%) cambiaron de puntuación. Inter-model: 90% dentro ±1,0 (n=89), mediana 0,42. Validación total: 277/502 ocupaciones (~55%) han sido evaluadas por al menos dos modelos independientes.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

7. Fase 4: Clasificación regulatoria EU AI Act

Cada ocupación recibe una clasificación de riesgo regulatorio según el Reglamento (UE) 2024/1689, basada en las categorías del Anexo III y el Artículo 5. El Reglamento clasifica sistemas de IA por contexto de uso, no ocupaciones. Por lo tanto, la clasificación se aplica en función de los usos típicos de IA que podrían desplegarse en cada contexto ocupacional.

Criterio de clasificación (v21): Una ocupación se clasifica como 'alto riesgo' solo si los trabajadores de esa ocupación despliegan, operan o interaccionan directamente con sistemas de IA que caen bajo el Anexo III. Ocupaciones que son meramente sujetas a decisiones de sistemas de IA operados por terceros (ej. trabajadores gestionados por algoritmos de turnos, candidatos evaluados por IA de RRHH) no reciben clasificación de alto riesgo a nivel ocupacional — el sistema de IA del tercero es alto riesgo, no la ocupación del trabajador afectado (véase nota [47]).

Nivel de riesgo	Ocupaciones	Trabajadores	Ejemplos
Alto riesgo (Anexo III)	51	3.48M	Profesores, médicos, RRHH, policía, abogados, jueces
Riesgo limitado	4	145K	Teleoperadores, periodistas, traductores
Riesgo mínimo	447	18.83M	Camareros, albañiles, limpieza, conductores, operarios

Cambio v19→v21: 20 ocupaciones reclasificadas de 'alto riesgo' a 'riesgo mínimo' (1,70M trabajadores). Conductores de vehículos convencionales, operadores de maquinaria manual, personal de limpieza, cuidadores de animales y asistentes personales no despliegan sistemas de IA en contextos del Anexo III. Son sujetas a decisiones de IA, no operadoras de sistemas de IA. Véase nota [47].

8. Fase 5: La visualización

El resultado se presenta como un treemap interactivo donde cada rectángulo es una ocupación. El área es proporcional al número de empleados (EPA Q4 2025). El color representa la puntuación de exposición a la IA (0 a 10), utilizando una escala divergente desde azul oscuro (baja exposición) hasta tonos cálidos como ámbar y terracota (alta exposición).

Definición del 'Índice ponderado de exposición'

Fórmula: Índice = Empleo × Salario medio × (Score / 10)

Es un índice ponderado que refleja dónde se concentra la masa salarial en relación con la exposición teórica a la IA. **No es una predicción de pérdidas salariales, ahorro potencial, ni masa salarial 'amenazada'.** La evidencia empírica (Anthropic, febrero 2026) muestra gaps significativos entre exposición teórica y adopción real. No debe citarse como 'X mil millones en riesgo'.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

9. Qué dicen los datos

Las profesiones más expuestas

Las ocupaciones con mayor exposición a la IA son aquellas cuyo trabajo principal consiste en procesar información digital: grabadores de datos (9,0), diseñadores gráficos y multimedia (8,5), desarrolladores de software (8,5), estadísticos (8,0), empleados de contabilidad (8,0), empleados administrativos de back-office (8,0), telefonistas (8,0), codificadores y correctores (8,0), y profesionales del derecho no clasificados (8,0). El patrón es claro: si tu trabajo vive en una pantalla y consiste en transformar información de un formato a otro, la IA actual ya puede hacer una parte significativa de él.

Las profesiones más protegidas

En el extremo opuesto: peluqueros (1,0), cuidadores de animales (1,0), personal de limpieza (1,0), empleados domésticos (1,0) y asistentes personales (1,0). También los educadores infantiles y los bomberos, donde la presencia humana es literalmente irreducible.

La gran masa intermedia

La mayoría de las ocupaciones españolas se sitúan en una zona intermedia (3-5) donde la IA aumenta la productividad, pero no sustituye al profesional. Esto incluye a médicos, profesores, ingenieros, y la mayoría de los operadores industriales.

El contexto español: por qué la exposición media es moderada

La puntuación media ponderada de España (3.7 sobre 10) refleja la estructura específica de su economía: (1) composición sectorial con peso desproporcionado de hostelería, construcción y agricultura; (2) factor regulatorio del EU AI Act y supervisión AESIA; (3) tejido de micro pymes (99% del total, solo 8-21% usa IA según la fuente).

Análisis de sensibilidad del umbral ≥7

La cifra de '12.5% de trabajadores en alta exposición' utiliza un umbral de ≥7,0 en la escala 0-10. Este umbral es una convención — no una frontera natural — y la cifra es sensible a su elección:

Umbral	% trabajadores	Trabajadores	Ocupaciones
≥6,0	20.2%	4.53M	90
≥6,5	15.7%	3.52M	63
≥7,0 (base)	12.5%	2.81M	47
≥7,5	11.4%	2.56M	41
≥8,0	5.0%	1.12M	12

Tras la re-puntuación por sub-componentes de las 88 ocupaciones en 7,0 (Paso 3d) y las 89 en 5,0 (Paso 3e), la banda de sensibilidad se ha estrechado sustancialmente: desplazar el umbral ±0,5 puntos mueve la cifra entre el 11.4% y el 15.7% (frente al rango anterior de 9,0%–22,2%). Solo 6 ocupaciones permanecen en la puntuación exacta de 7,0 (véase nota [49]).

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

10. Lo que este análisis NO dice

Exposición no es desplazamiento. Una puntuación alta no significa que esa profesión vaya a desaparecer. La evidencia empírica (Anthropic Economic Index, febrero 2026) lo confirma: incluso en ocupaciones con mayor exposición teórica (~94%), la adopción real observada es solo ~33%. Este análisis mide la capacidad técnica de la IA para realizar tareas ocupacionales, no la viabilidad económica de dicha sustitución (véase nota [36]).

Los datos de empleo por ocupación son aproximados. La EPA solo publica empleo a nivel de gran grupo. Las cifras a 4 dígitos son estimaciones obtenidas mediante pesos del Censo 2021 a 3 dígitos, refinadas con contracción empírico-bayesiana (202 valores únicos de empleo). El 79,5% de las ocupaciones comparten su cifra de empleo con al menos otra ocupación. Las desviaciones a 2 dígitos respecto a los totales EPA publicados son sustanciales en algunos subgrupos (véase nota [45]).

Las puntuaciones son estimaciones, no mediciones. Las 325 ocupaciones no re-puntuadas son reproducibles (±0,5 puntos intra-modelo) y validadas inter-modelo (r = 0,715, kw = 0,667). Las 177 ocupaciones re-puntuadas por sub-componentes (Pasos 3d y 3e) tienen una validación inter-modelo más fuerte: 85-90% dentro de ±1,0 punto entre GPT 5.4 Thinking y Gemini 3 Thinking. Análisis Bland-Altman confirma ausencia de sesgo proporcional. Operan en incrementos de 0,5 puntos. Aunque la escala es nominalmente 0–10, el dataset contiene 17 valores únicos. Esto es una escala ordinal, no continua. La cifra de alta exposición (12.5%) tiene una banda de sensibilidad de [11.4%–15.7%] al variar el umbral ±0,5 puntos (véase nota [49]).

Los salarios son estimaciones ajustadas. 128 valores únicos, validados con MAPE 4,96% contra INE EES 2023. Los ~3,3M de autónomos están excluidos de la muestra salarial por diseño.

El índice ponderado de exposición no es una predicción. La cifra de 257,060M EUR es un índice calculado como Empleo × Salario × (Score/10). No es una estimación de pérdidas salariales, ahorro potencial, ni masa salarial 'amenazada'. No debe citarse como 'X mil millones en riesgo'.

La clasificación EU AI Act es a nivel ocupacional, no legal. El Reglamento clasifica sistemas de IA, no ocupaciones. La asignación de niveles de riesgo a ocupaciones es un proxy que indica dónde es probable que se desplieguen sistemas de IA regulados, no una determinación legal sobre la ocupación en sí (véase nota [47]).

No se captura la variabilidad regional ni la distinción tiempo completo/parcial (véase nota [39]).

11. Stack de validación completo

Esta sección resume las validaciones externas realizadas para esta versión del análisis:

11.1. Validación de empleo (1 dígito)

Los totales de empleo por gran grupo de la EPA Q4 2025 se extrajeron de la API Tempus del INE (tabla 65134, datos definitivos publicados 27/01/2026). Nuestro dataset reproduce estos totales con desviación del ±0,00% (diferencia máxima: 47 personas sobre 22,46M).

11.2. Validación de puntuaciones IA (inter-modelo)

100 ocupaciones estratificadas por rango de puntuación fueron re-puntuadas ciegamente por GPT-4o. Resultados: r = 0,715, ICC = 0,701, kw = 0,667. El 84% de las ocupaciones coinciden dentro de ±2,0 puntos. El sesgo sistemático (+0,28 hacia el centro) es interpretable y no invalida el ranking. Análisis Bland-Altman (v11a): sin sesgo proporcional confirmado.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

11.3. Validación salarial (16 grupos INE)

Las 128 estimaciones salariales se agregaron en los 16 grupos publicados por el INE (EES 2023, tabla 28186). MAPE post-corrección: 4,96%. Todas las desviaciones inferiores al 10%. Validación realizada por Manus AI.

11.4. Revisión adversarial multi-modelo

El documento metodológico fue sometido a revisión adversarial por 7+ modelos de IA independientes (Grok ×2, Perplexity ×2, Manus ×2, Gemini, Claude). Las correcciones incorporadas incluyen: relabelling del índice de masa salarial, corrección DESI 2024→2023, reclasificación EU AI Act (eliminación de categoría 'prohibido', reclasificación de 20 ocupaciones en v21), correcciones de sector (v18), contracción empírico-bayesiana (v19), corrección de tipo de datos CNO (v21), divulgación de sensibilidad del umbral (v21), reconciliación de cifras con el dataset publicado, y re-puntuación por sub-componentes de 177 ocupaciones frontera (88 cluster 7.0 + 89 cluster 5.0) con validación inter-modelo GPT 5.4 / Gemini 3 (v22-v23).

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

12. Tabla de correspondencia de versiones

Metodología	Dataset	Fecha	Cambio principal
v17	v5	Feb 2026	Corrección salarial (MAPE 7,55% → 4,96%)
v18	v6	Mar 2026	Reclasificación 12 ocupaciones CNO 76xx (sector)
v19	v7	Mar 2026	Contracción empírico-bayesiana empleo (202 valores)
v20	v7	Mar 2026	Refinamiento documentación, adición Bland-Altman y validaciones cruzadas
v21	v8	Mar 2026	CNO strings, reclasif. EU AI Act (51), sensibilidad umbral, reconciliación cifras
v22	v9	Mar 2026	Re-scoring sub-componente 88 occ (7.0→3), GPT 5.4 + Gemini 3
v23	v10	Mar 2026	Re-scoring sub-componente 89 occ (5.0→dispersión), GPT 5.4 + Gemini 3

13. Fuentes y referencias

INE. Encuesta de Población Activa, Q4 2025. Microdatos (EPA_2025T4.tab, 107.497 registros). Publicados 27/01/2026.

INE. Clasificación Nacional de Ocupaciones CNO-11. 449 grupos primarios oficiales.

SEPE. Observatorio de las Ocupaciones. 502 grupos primarios CNO-11 (expansión SEPE).

INE. Encuesta de Estructura Salarial 2023. Tabla 28186: salario bruto medio anual por subgrupo CNO.

INE. Censo de Población y Viviendas 2021. Estructura ocupacional (3 dígitos CNO-11).

INE. API Tempus, Tabla 65134: Ocupados por sexo y ocupación. Datos Q4 2025.

Comisión Europea. Digital Economy and Society Index (DESI) 2023. Perfil de España.

Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo (EU AI Act). Anexo III, Arts. 5 y 6.

Real Decreto 729/2023. Estatuto de la AESIA. BOE de 2 de septiembre de 2023.

OCDE. AI and Work. Employment Outlook 2024. España: 28% empleos en riesgo (todas tecnologías); 5,9% alto riesgo IA; 27,4% exposición GenAI.

INSEE (Francia). Données salariales par profession détaillée. Proxy salarial intra-grupo.

INE-PT (Portugal). Quadros de Pessoal. Proxy salarial intra-grupo.

Eloundou, T., Manning, S., Mishkin, P. y Rock, D. (2023). 'GPTs are GPTs'. OpenAI/UPenn. arXiv:2303.10130v5.

Brynjolfsson, E., Mitchell, T. y Rock, D. (2018). 'What Can Machines Learn…' AEA Papers and Proceedings, 108:43-47.

Frey, C. B. y Osborne, M. A. (2017). 'The Future of Employment'. Technological Forecasting and Social Change, 114:254-280.

Anthropic. The Anthropic Economic Index. Febrero 2026. Brecha exposición teórica (~94%) vs adopción real (~33%).

Nedelkoska, L. y Quintini, G. (2018). 'Automation, skills use and training.' OECD Social, Employment and Migration Working Papers, No. 202.

Acemoglu, D. (2024). 'The Simple Macroeconomics of AI'. Economic Policy.

Felten, E., Raj, M. y Seamans, R. (2021). 'Occupational, industry, and geographic exposure to AI'. Strategic Management Journal, 42(12):2195-2217.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Apéndice A: Notas Técnicas Detalladas

Este apéndice recopila las 50 notas técnicas que proporcionan detalle metodológico adicional. Se han agrupado por tema para facilitar la consulta.

Notas sobre inventario de ocupaciones

[1] El INE define oficialmente 449 grupos primarios a 4 dígitos en la CNO-11. El SEPE amplía esta cifra a 502. Nuestro dataset utiliza los 502 códigos del SEPE.

[2] Las ocupaciones emergentes (IA, apps móviles) se clasifican en categorías residuales como el código 2599.

Notas sobre datos de empleo

[3] Los microdatos públicos de la EPA contienen la variable CNAE (actividad económica) a 4 dígitos, pero CNO (ocupación) solo a 1 dígito. Son variables distintas.

[4] Ninguna tabla pública de la EPA publica empleo a 4 dígitos CNO. Las celdas con población expandida inferior a 5.000 individuos están sujetas a errores de muestreo inaceptables.

[5] El tamaño muestral por gran grupo oscila entre 251 (Grupo 0: Militar) y 9.576 (Grupo 5: Servicios).

[6] Los microdatos del Censo 2021 nacional proporcionan la ocupación a 3 dígitos CNO (136 subgrupos), no a 4 dígitos. Los ficheros provinciales solo proporcionan 2 dígitos.

[7] Es un error econométrico frecuente y grave utilizar el volumen de contratos registrados del SEPE como proxy del empleo. Los contratos son flujos (altas), no stock.

[45] Contracción empírico-bayesiana (Empirical Bayes shrinkage) en estimaciones de empleo a 3 dígitos CNO (v19). Los totales de empleo a nivel de subgrupo de 3 dígitos se refinaron combinando la estimación proporcional derivada de la EPA con el prior censal (Censo 2021, 145 subgrupos) mediante contracción en espacio logarítmico con ruido heteroscedástico: $\theta_shrunk = \exp[(1-B)\cdot\log(y_EPA) + B\cdot\log(\mu_Censo)]$, donde $B = \sigma^2/(\sigma^2+\tau^2)$. Los factores B oscilan entre 0,05 y 0,97. Los totales EPA a 1 dígito se preservan con exactitud absoluta mediante el algoritmo del resto mayor. Resultado: 202 valores únicos. Limitación: dentro de cada subgrupo de 3 dígitos, las ocupaciones a 4 dígitos siguen recibiendo partes iguales del total contraído.

[46] Formato de códigos CNO (v21). Los códigos CNO se almacenan como cadenas de texto con ceros a la izquierda ('0011', '0012', '0020'). En versiones v5–v7 se almacenaban como enteros, eliminando el cero inicial de las ocupaciones militares.

Notas sobre datos salariales

[8] La Muestra Continua de Vidas Laborales (MCVL) es una fuente potencial de validación no utilizada.

[9] El multiplicador educativo no contabiliza gradientes educación-salario específicos por sector.

[10] El proxy Francia/Portugal asume similitud estructural entre economías del sur de Europa. No validado empíricamente para cada grupo ocupacional individual.

[11] Los datos salariales se refieren al salario bruto medio anual. Los autónomos (~3,3M personas) están excluidos de la EES por diseño.

[12] La EES 2023 se refiere a salarios del año de referencia 2022. No se ha aplicado deflactor temporal.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Notas sobre puntuación de exposición a la IA

[13] Las puntuaciones fueron generadas mediante LLM (Gemini 2.5 Pro) en un solo pase a temperatura 0,2, siguiendo Brynjolfsson et al. (2018) y Eloundou et al. (2023). Validación inter-modelo con GPT-4o: r = 0,715, ICC = 0,701, kw = 0,667.

[14] Las puntuaciones reflejan el estado de las capacidades de la IA a marzo de 2026.

[15] Las puntuaciones se asignan a nivel de ocupación completa, no de tarea individual (véase nota [38]).

[16] Los 5 factores de calibración no están calibrados contra datos empíricos de adopción real de IA. La evidencia empírica (Anthropic Economic Index, febrero 2026) muestra que la exposición teórica puede diferir significativamente de la adopción real: en ocupaciones informáticas, ~94% teórica vs ~33% observada.

[17] Los efectos de interacción entre factores no se modelan explícitamente.

[27] Reproducibilidad estimada: ±0,5 puntos intra-modelo. Validación inter-modelo (v10): r = 0,715. Análisis Bland-Altman (v11a): sin sesgo proporcional, límites ±1,96 DE: -2,77 a +3,33.

[30] Calibración por anclaje few-shot. Las rúbricas incluyen ejemplos explícitos a diferentes niveles (score 1: albañil, score 5: conductor, score 9: teleoperador) como anclas de calibración.

Notas sobre clasificación EU AI Act

[18] La clasificación se basa en el uso previsto de la IA en cada ocupación, no en productos de IA específicos.

[19] Solo se modela la clasificación basada en casos de uso del Anexo III.

[20] Las exenciones del Art. 6(3) no se capturan: los sistemas del Anexo III NO son de alto riesgo si no influyen materialmente en la toma de decisiones. Esto produce una sobre-clasificación conservadora.

[28] El Art. 5 prohíbe determinadas prácticas de IA (scoring social, manipulación subliminal), no el ejercicio de profesiones. La clasificación no incluye categoría 'prohibido' a nivel de ocupación.

[47] Criterio de reclasificación EU AI Act (v21). 20 ocupaciones reclasificadas de 'alto riesgo' a 'riesgo mínimo'. Criterio: una ocupación se clasifica 'alto riesgo' solo si sus trabajadores despliegan o interaccionan directamente con sistemas de IA del Anexo III. Ser sujeto pasivo de decisiones de un sistema de IA de alto riesgo operado por un tercero no cualifica. Categorías: (a) conductores/operadores de vehículos convencionales (11 ocup.); (b) limpieza, cuidadores y asistentes personales (9 ocup.). Educación y sanidad mantienen alto riesgo (Anexo III Cat. 3 y 5). Campo eu_ai_act_v7 preserva clasificación original.

Notas sobre visualización

[21] El algoritmo squarify optimiza la relación de aspecto, no la agrupación por sector.

[22] El gradiente de color puede no ser completamente accesible para usuarios con daltonismo.

Notas sobre limitaciones

[23] No se contabiliza la creación de nuevos empleos por la IA.

[24] No se distingue entre empleo a tiempo parcial y a tiempo completo.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

[25] El análisis es estático (fotografía de marzo de 2026).

[26] No se proporciona un cronograma de adopción específico por sector.

Notas sobre validación

[33] El MAPE de 4,96% se refiere a la validación post-corrección. El MAPE pre-corrección era 7,55%, con una desviación del -36,4% en Grupo I que fue corregida.

[34] La validación inter-modelo cubre ~55% de la muestra: 100 ocupaciones por scoring holístico (GPT 5.3) + 88 por sub-componentes cluster 7.0 + 89 por sub-componentes cluster 5.0 = 277/502. Una validación completa (502 ocupaciones) es una extensión natural para futuras versiones.

[35] El análisis Bland-Altman (v11a) confirma ausencia de sesgo proporcional entre modelos. Los límites de acuerdo al 95% (-2,77 a +3,33 puntos) son amplios pero aceptables para una escala 0-10 con puntuación subjetiva. Ninguna herramienta comparable ha publicado validación inter-modelo con análisis Bland-Altman.

[48] Sensibilidad del umbral de alta exposición (v23). Tras la re-puntuación por sub-componentes (Pasos 3d y 3e, v22-v23), la concentración en 7,0 se ha reducido de 88 a 6 ocupaciones y la concentración en 5,0 de 102 a 15 ocupaciones. La cifra de 12.5% (score ≥7,0) tiene una banda de sensibilidad de [11.4% (≥7,5) a 15.7% (≥6,5)], un rango de 4.3 puntos porcentuales frente a los 13,2 puntos de la versión anterior. La fragilidad del umbral ha sido sustancialmente mitigada.

Notas adicionales: contexto económico, comparabilidad y dimensiones pendientes

[36] Viabilidad económica (Acemoglu). Este análisis mide la capacidad técnica de la IA para realizar tareas ocupacionales, no la viabilidad económica de dicha sustitución. Acemoglu (2024) estima que solo ~4,6% de las tareas son actualmente automatizables con ROI positivo. En España, donde los salarios medios (~28.000 EUR) son inferiores al mercado estadounidense, el umbral de viabilidad económica para la sustitución es probablemente más alto.

[37] Índice AIOE (Felten, Raj & Seamans). La comparación directa no es posible: AIOE opera a nivel de habilidad (O*NET) vs ocupación (CNO-11). Un crosswalk CNO-11 → ISCO-08 → SOC → O*NET permitiría validación futura.

[38] Puntuación a nivel de ocupación (diseño deliberado). La CNO-11 no dispone de un inventario de tareas equivalente al O*NET. Puntuar a nivel de ocupación sacrifica granularidad intra-ocupacional pero evita el ruido acumulado de un crosswalk de 19.000 tareas. La tipología de impacto (sustitución / híbrido / aumentación) proporciona la señal direccional que una puntuación única no captura.

[39] Dimensiones disponibles pero no integradas: (a) Distribución regional (CCAA) — datos extraídos de microdatos EPA Q4 2025, disponibles para análisis NUTS-2 futuro. (b) Descomposición por género — concentración femenina en ocupaciones administrativas (alta exposición) y cuidados (baja exposición) sugiere impactos desiguales. (c) Economía informal — estimada en 18-20% del PIB, concentrada en sectores de baja exposición. (d) Distinción tiempo completo/parcial — ~2,5M trabajadores a tiempo parcial; el índice asume implícitamente equivalencia a tiempo completo.

[40] Simplificación $\alpha/\beta/\zeta$ y escala continua. Eloundou descompone la exposición en α (~15%), β (~30%) y ζ (~50%). Este análisis subsume los tres niveles en una puntuación 0-10. La tipología de impacto compensa parcialmente esta limitación.

[41] Umbral de exposición: escala continua vs. binaria. El 12.5% con score ≥7 refleja la calibración española de 5 factores más la re-puntuación sub-componente de 177 ocupaciones frontera (v22-v23).

[42] Concordancia modelo-modelo vs. modelo-humano. La concordancia modelo-modelo tiende a ser mayor por sesgos compartidos en entrenamiento LLM. La ausencia de anotadores humanos es una limitación reconocida.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

[43] Ocupaciones sin exposición: ninguna recibe 0. Puntuación mínima 1,0 (componente administrativo mínimo). Las ocupaciones con 1,0 son funcionalmente equivalentes a las de exposición cero de Eloundou.

[44] Análisis quintiles salariales: r = 0,489 (no ponderado), r = 0,414 (ponderado). Confirma patrón Eloundou: salarios más altos correlacionan con mayor exposición. Q1 concentra el 44% del empleo con exposición baja (2,98). Análisis ejecutado sobre spain_502_v6_sectorfixed.json. Los cambios en v10 (177 ocupaciones re-puntuadas) afectan a los quintiles medios y superiores; re-análisis pendiente.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Apéndice B: Validación Inter-modelo (detalle)

Para evaluar la robustez y reproducibilidad de las puntuaciones de exposición a la IA, se realizó una validación ciega inter-modelo. Se seleccionaron 100 ocupaciones mediante muestreo estratificado por bandas de puntuación (baja: 0-3, media: 3-6, alta: 6-10) y se sometieron a una evaluación independiente por GPT-4o, utilizando la misma rúbrica de puntuación pero sin acceso a las puntuaciones originales asignadas por Gemini 2.5 Pro.

Metodología

El evaluador ciego (GPT-4o) recibió únicamente el nombre oficial CNO-11 y el código de cada ocupación, junto con la rúbrica de puntuación de 0 a 10. Las puntuaciones se generaron en bloques de 10 ocupaciones para mantener la coherencia interna. No se proporcionó ninguna referencia a las puntuaciones originales.

Resultados

Métrica	Valor	Interpretación
Correlación de Pearson (r)	0,715	Buena — rango 'good' para inter-rater reliability
ICC(2,1)	0,701	Buena — acuerdo consistente entre modelos
Kappa ponderado (kw cuadrático)	0,667	Acuerdo sustancial (convención Landis-Koch)
Sesgo medio (GPT - Gemini)	+0,28 puntos	GPT puntúa ligeramente más alto
MAD (desviación absoluta mediana)	1,0 punto	En una escala 0-10, excelente
Ocupaciones dentro de ±1,0 punto	61%	Acuerdo estrecho
Ocupaciones dentro de ±2,0 puntos	84%	Acuerdo amplio
Desacuerdos >2,0 puntos	16 (de 100)	Concentrados en 2 clusters interpretables

Figura B.1: Scatter plot Gemini vs GPT-4o (izquierda) y análisis de Bland-Altman (derecha). Puntos azules: desacuerdo ≤1,0 pts (61%). Naranja: 1,0-2,0 pts (23%). Rojo: >2,0 pts (16%).

Análisis de desacuerdos

El análisis de Bland-Altman revela un patrón de compresión sistemático: GPT-4o tiende a asignar puntuaciones más altas que Gemini en ocupaciones de baja exposición y más bajas en ocupaciones de alta exposición. Los 16 desacuerdos mayores de 2 puntos se concentran en dos clusters interpretables: (1) operadores industriales, donde GPT pondera más el potencial de robótica, y (2) profesionales de nicho, donde Gemini pondera más el componente digital.

Los resultados confirman que las puntuaciones son robustas y reproducibles entre modelos LLM independientes, con un acuerdo sustancial (kw > 0,60) y una correlación fuerte (r > 0,70). La compresión hacia la media por parte de GPT es un sesgo conocido en evaluaciones LLM y no compromete la validez ordinal de la clasificación.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

B.2: Validación inter-modelo de sub-componentes (v22-v23)

Las 177 ocupaciones re-puntuadas por descomposición en 4 sub-componentes (D, C, F, R) fueron evaluadas independientemente por GPT 5.4 Thinking y Gemini 3 Thinking. La figura B.2 muestra el acuerdo inter-modelo sobre los scores brutos (antes del re-escalado) para ambos clusters.

Figura B.2: Scatter plot (izquierda) y Bland-Altman (derecha) para las 177 ocupaciones re-puntuadas por sub-componentes. Azul oscuro: cluster 7,0 (n=88). Verde: cluster 5,0 (n=89). El acuerdo inter-modelo en sub-componentes (r = 0,953 combinado) es sustancialmente superior al del scoring holístico (r = 0,715), confirmando que la descomposición dimensional reduce la varianza inter-modelo.

Métrica	Cluster 7,0 (n=88)	Cluster 5,0 (n=89)	Combinado (n=177)
Correlación (r)	0,943	0,952	0,953
Sesgo medio (GPT–Gemini)	–0,00	+0,31	+0,15
Dentro de ±1,0 punto	86% (76/88)	90% (80/89)	88% (156/177)
Dentro de ±2,0 puntos	99% (87/88)	99% (88/89)	99% (175/177)
Mediana |diferencia|	0,42	0,42	0,42
Límites Bland-Altman 95%			[–1,12; +1,43]

Hallazgo clave: La descomposición en sub-componentes mejora drásticamente el acuerdo inter-modelo (r = 0,953 vs 0,715), confirma ausencia de sesgo proporcional en el Bland-Altman, y produce límites de acuerdo al 95% de [–1,12; +1,43] — mucho más estrechos que los del scoring holístico [–2,77; +3,33]. Esto valida que el protocolo de 4 dimensiones captura aspectos objetivables de las ocupaciones que el scoring holístico dejaba a la interpretación subjetiva del modelo.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Apéndice C: Validación Salarial Cruzada (INE EES 2023)

Las estimaciones salariales del modelo fueron validadas contra los datos oficiales de la Encuesta de Estructura Salarial 2023 del INE (tabla 28186). Se calculó la media ponderada por empleo de las estimaciones salariales para cada uno de los 16 grupos ocupacionales principales (A-P) y se comparó con las cifras publicadas por el INE.

Resultados de la validación (post-corrección)

Grupo	Nombre	INE (EUR)	Nuestro (EUR)	Desv. %
A	Directores y gerentes	60.986	57.922	-5,0%
B	Técnicos prof. científicos (salud/enseñanza)	38.858	38.099	-2,0%
C	Otros técnicos prof. científicos	42.997	40.100	-6,7%
D	Técnicos; profesionales de apoyo	33.243	31.381	-5,6%
E	Empleados oficina (sin atención público)	28.148	25.564	-9,2%
F	Empleados oficina (con atención público)	22.263	24.018	+7,9%
G	Trab. restauración, comercio, personales	18.028	17.526	-2,8%
H	Trab. servicios salud y cuidado	18.739	19.717	+5,2%
I	Trab. protección y seguridad	35.215	33.667	-4,4%
J	Trab. cualificados agro/forestal/pesca	24.551	23.937	-2,5%
K	Trab. cualificados construcción	23.321	23.713	+1,7%
L	Trab. cualificados industrias manuf.	26.345	23.881	-9,4%
M	Operadores instalaciones/maquinaria fijas	28.852	28.446	-1,4%
N	Conductores/operadores maquinaria móvil	23.536	22.895	-2,7%
O	Trab. no cualificados en servicios	15.277	14.600	-4,4%
P	Peones agricultura/pesca/constr./industria	20.817	19.051	-8,5%
	MAPE (Error absoluto medio porcentual)			4,96%

Análisis de las discrepancias principales

Grupo I (Protección y seguridad): La desviación original de -36,4% fue la más significativa. La cifra oficial del INE (35.215 EUR) refleja la alta prevalencia de empleados del sector público (policías, guardias civiles, bomberos), cuyos salarios incluyen complementos significativos (trienios, peligrosidad, nocturnidad, destino). Tras la corrección, la desviación se redujo a -4,4%.

Grupo M (Operadores maquinaria fija): La desviación de -12,0% se explicó por los convenios colectivos del sector metal y químico. Tras el ajuste del +12%, la desviación se redujo a -1,4%.

Grupo H (Salud y cuidado): La sobrestimación de +9,7% se debió a cuidadoras a domicilio y trabajadoras de guarderías cuyos salarios se anclan al SMI (15.120 EUR en 2023). Tras la corrección, +5,2%.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Apéndice D: Comparativa Internacional — Estados Unidos

En 2025-2026 se publicó un análisis de referencia sobre exposición laboral a la IA para el mercado estadounidense (Andrej Karpathy, 'Jobs'), utilizando datos del Bureau of Labor Statistics (BLS) y la taxonomía O*NET.

Comparativa metodológica

Dimensión	Análisis EE.UU.	Este análisis (España v23)
Taxonomía	O*NET / SOC (~800 ocup. BLS)	CNO-11 (502 ocupaciones SEPE)
Datos de empleo	BLS OEWS — directo por ocupación	EPA Q4 2025 + Censo 2021 + Bayes
Datos salariales	BLS OEWS — mediano directo	EES 2023 a 2 díg. + ajustes (MAPE 4,96%)
Motor de puntuación	LLM único (Gemini Flash), T=0,2	Gemini 2.5 Pro + GPT-4o + sub-comp. GPT 5.4/Gemini 3 (177 occ)
Calibración estructural	Ninguna (puntuaciones brutas)	5 factores: DESI, servicios, laboral, EU AI Act, AESIA
Clasif. regulatoria	No incluida	EU AI Act: 3 niveles de riesgo
Tipología de impacto	No incluida	Sustitución / Híbrido / Aumentación
Validación inter-modelo	No incluida	r = 0,715, ICC = 0,701, kw = 0,667
Validación salarial	Directa (BLS)	MAPE 4,96% vs INE EES 2023
Documentación	README de código abierto	PDF 25+ páginas, 50 notas técnicas

Contextualización OCDE

La cifra del 28% de empleos en riesgo de automatización (OCDE, Employment Outlook 2024) se refiere a todas las tecnologías de automatización (robótica industrial, software tradicional, e IA), no exclusivamente a la IA. Las cifras OCDE específicas de IA para España son: 5,9% alto riesgo automatización IA; 27,4% exposición IA generativa. Nuestro 12.5% (score ≥7) mide exposición teórica calibrada a IA en sentido amplio. No es directamente comparable a ninguna cifra OCDE individual.

Parámetro	EE.UU.	España	Causa principal
Exposición media	~4,6	3.7	Peso servicios físicos + calibración 5 factores + sub-componentes
% alta exposición (≥7)	~27%	12.5% [11.4%–15.7%]	Menos economía del conocimiento + sub-componentes
Clasif. regulatoria	No incluida	3 niveles EU AI Act	No existe marco federal EE.UU.
Alto riesgo EU AI Act	N/A	51 ocup. (3.48M)	Reclasificado v21
Factor fricción laboral	No aplicado	1-5% según sector	Protección empleo OCDE: 3er más estricto
Granularidad salarial	~800 valores directos	128 valores (ajustados)	INE publica a 2 dígitos
Granularidad empleo	Directo por ocupación	Distribución desde 1 dígito + Bayes	EPA anonimiza CNO a 1 dígito
Re-scoring frontera	No incluido	177 occ. × 4 sub-comp. × 2 modelos	v22-v23

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

La banda [11.4%–15.7%] refleja la sensibilidad del umbral ≥7 tras la re-puntuación por sub-componentes (véase notas [48] y [49]). La diferencia España–EE.UU. (0.9 puntos en media) refleja tanto la calibración estructural como la mayor resolución obtenida mediante descomposición dimensional.

Notas técnicas de la comparativa

[29] Una comparativa directa ocupación-por-ocupación requeriría un diccionario O*NET/SOC ↔ CNO-11.

[31] La cifra OCDE del 28% utiliza la metodología Nedelkoska & Quintini (2018) basada en PIAAC.

[32] La brecha teórico-práctica (Anthropic, 2026) sugiere que los factores de calibración para España podrían ser insuficientes para capturar la brecha total.

© 2026 Álvaro de Nicolás. Todos los derechos reservados.

Apéndice E: Correlación salario-exposición (Eloundou)

Eloundou et al. (2023) encuentra que salarios más altos se asocian con mayor exposición a LLMs — un resultado contraintuitivo. Para verificar si España replica este patrón, se calculó la exposición media ponderada por empleo para cada quintil salarial:

Quintil salarial	Exp. media pond.	Ocupaciones	Empleo	% empleo
Q1 (≤23.323€)	2,98	133	9.877.912	44,0%
Q2 (23.323–27.130€)	4,09	68	2.648.307	11,8%
Q3 (27.130–31.581€)	5,24	138	3.676.126	16,4%
Q4 (31.581–36.915€)	4,85	77	3.282.534	14,6%
Q5 (>36.915€)	5,20	86	2.978.407	13,3%

Veredicto: Confirma Eloundou. Salarios más altos correlacionan con mayor exposición en España. Correlación de Pearson (no ponderado): r = 0,489 ($p = 1{,}45\times10^{-31}$). Correlación ponderada por empleo: r = 0,414. Ambas altamente significativas.

Hallazgo España-específico: Q1 concentra el 44% de todo el empleo (9,9M trabajadores) con exposición baja (2,98). Esto refleja el peso desproporcionado de la hostelería, limpieza y servicios físicos en la economía española — y explica por qué la media ponderada nacional (4,0) es menor que la de EE.UU. (~4,6): no es solo la calibración con 5 factores, es que casi la mitad de los trabajadores españoles están en ocupaciones de baja remuneración y baja exposición.

[44] Análisis ejecutado sobre spain_502_v6_sectorfixed.json. Quintiles calculados sobre las 502 ocupaciones. Correlación de Pearson calculada con scipy.stats. La ponderación por empleo reduce la correlación de 0,489 a 0,414 porque las ocupaciones de gran tamaño (vendedores, limpiadores) tienen puntuaciones moderadas que comprimen la varianza. Los cambios en v10 (177 ocupaciones re-puntuadas) afectan a los quintiles medios y superiores.

Análisis realizado por alvarodenicolas.com · Marzo 2026

Datos abiertos · Metodología reproducible · Herramienta interactiva disponible en la web

50 notas técnicas documentan la totalidad de supuestos, proxies y limitaciones

A. de Nicolás, M. Sureda

© 2026 Álvaro de Nicolás. Todos los derechos reservados.